BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ TP.HCM

ĐỒ ÁN MÔN HỌC

BIG DATA

Ngành: **KHOA HỌC DỮ LIỆU**

Chuyên ngành: **KHOA HỌC DỮ LIỆU**

Giảng viên hướng dẫn: **ThS. Nguyễn Quang Phúc**

Sinh viên thực hiện:

2286400009 – Bùi Minh Huy

2286400028 – Nguyễn Thị Thanh Tâm

2286400042 – Trần Lê Vân

TP. Hồ Chí Minh, 2026

MỤC LỤC

DANH MỤC CÁC KÝ HIỆU, CHỮ VIẾT TẮT VÀ TỪ KHÓA . . . . . **iii**

DANH MỤC CÁC BẢNG . . . . . **iv**

DANH MỤC CÁC HÌNH VẼ, ĐỒ THỊ . . . . . **v**

CHƯƠNG 1: TỔNG QUAN VỀ BIG DATA **1**

1.1 Tính chất đặc trưng của Big Data **1**

1.1.1 Volume ***1***

1.1.2 Velocity ***2***

1.1.3 Variety ***2***

1.1.4 Veracity ***3***

1.1.5 Value ***3***

1.1.6 Variability ***3***

1.1.7 Visualization ***4***

1.2 Kiến trúc Big Data **4**

1.2.1 Thu thập dữ liệu ***5***

1.2.2 Lưu trữ dữ liệu ***6***

1.2.3 Xử lý và biến đổi dữ liệu ***6***

1.2.4 Phân tích và khai phá dữ liệu ***6***

1.2.5 Truy cập và trực quan hóa ***7***

1.2.6 Tri thức, hỗ trợ ra quyết định và ứng dụng nghiệp vụ ***7***

1.2.7 Bảo mật và quản trị hệ thống ***7***

1.3 Ứng dụng của Big Data trong các lĩnh vực **8**

1.4 Các công nghệ xử lý dữ liệu lớn **9**

CHƯƠNG 2: GIỚI THIỆU APACHE SPARK **11**

2.1 Kiến trúc Spark **11**

2.2 So sánh Spark với MapReduce **11**

2.3 Các thành phần quan trọng trong Spark **11**

2.3.1 Spark Core (RDD, DataFrame, Dataset) ***11***

2.3.2 Spark SQL *11*
2.3.3 Spark Streaming *11*
2.3.4 Spark GraphX *11*
2.3.5 Spark MLlib *11*
CHƯƠNG 3: PHÂN TÍCH VÀ KHÁM PHÁ DỮ LIỆU **12**
3.1 Môi trường thực nghiệm **12**
3.2 Dữ liệu thực nghiệm **12**
3.3 Kiểm tra chất lượng dữ liệu **13**
3.4 Phân bố nhãn và thống kê mô tả **14**
3.5 Phân tích đa chiều với Spark SQL **17**
3.5.1 Phân tích gian lận theo danh mục giao dịch *17*
3.5.2 Phân tích gian lận theo merchant *18*
3.5.3 Phân tích gian lận theo giới tính *18*
3.5.4 Phân tích gian lận theo nhóm tuổi *19*
3.5.5 Phân tích gian lận theo thời gian *20*
3.5.6 Phân tích gian lận theo bang *22*
3.6 Phân tích khoảng cách giữa khách hàng và merchant **23**
3.7 So sánh tập huấn luyện và tập kiểm tra **23**
CHƯƠNG 4: THỰC NGHIỆM VÀ KẾT QUẢ **24**
4.1 Tiền xử lý dữ liệu **24**
4.2 Xây dựng mô hình **24**
4.3 Đánh giá và so sánh mô hình **24**
4.4 Thực nghiệm Streaming **24**
4.5 Phân tích đồ thị giao dịch **24**
4.6 Thảo luận kết quả **24**
CHƯƠNG 5: KẾT LUẬN **25**
TÀI LIỆU THAM KHẢO **26**

DANH MỤC CÁC KÝ HIỆU, CHỮ VIẾT TẮT VÀ TỪ KHÓA

DANH MỤC CÁC BẢNG

3.1 Thống kê mô tả biến số tiền giao dịch `amt` trong tập huấn luyện 15
3.2 Thống kê số tiền giao dịch theo nhãn `is_fraud` 16

DANH MỤC CÁC HÌNH VẼ, ĐỒ THỊ

1.1 Các đặc điểm và tính chất quan trọng của Big Data 1

1.2 Caption 4

3.3 Phân bố nhãn giao dịch trong tập huấn luyện và tập kiểm tra 14

3.4 Phân bố số tiền giao dịch theo nhãn trên thang đo logarit 16

3.5 Số lượng và tỷ lệ giao dịch gian lận theo danh mục giao dịch 17

3.6 Top 10 merchant có số lượng giao dịch gian lận nhiều nhất 18

3.7 Số lượng và tỷ lệ giao dịch gian lận theo giới tính 19

3.8 Số lượng và tỷ lệ giao dịch gian lận theo nhóm tuổi 19

3.9 Số lượng và tỷ lệ giao dịch gian lận theo giờ trong ngày 20

3.10 Tỷ lệ giao dịch gian lận theo ngày trong tuần 21

3.11 Tỷ lệ giao dịch gian lận theo tháng 22

3.12 Top 10 bang có tỷ lệ giao dịch gian lận cao nhất 22

CHƯƠNG 1: TỔNG QUAN VỀ BIG DATA

1.1 Tính chất đặc trưng của Big Data

Big Data hay gọi là dữ liệu lớn là thuật ngữ dùng để chỉ các tập dữ liệu có khối lượng khổng lồ, tốc độ tăng trưởng nhanh, đa dạng về định dạng, vượt quá khả năng xử lý của các công cụ truyền thống. Nói một cách đơn giản, đó là những tập dữ liệu mà bạn không thể mở và xử lý bằng Excel được[1].

Big Data không chỉ đơn giản là "dữ liệu lớn". Để được coi là Big Data, dữ liệu cần phải có một số đặc điểm và tính chất nhất định, thường được mô tả bằng mô hình 5V là Volume, Velocity, Variety, Veracity, Value và ngày càng được mở rộng thành 6V, 7V.

Mô hình 5V, 6V hay 7V không phải là tiêu chuẩn cố định. Chúng là cách để nhấn mạnh những khía cạnh quan trọng của Big Data. Hiểu rõ các đặc điểm này giúp chúng ta lựa chọn đúng công nghệ, kỹ thuật, và phương pháp để khai thác tối đa giá trị từ dữ liệu.

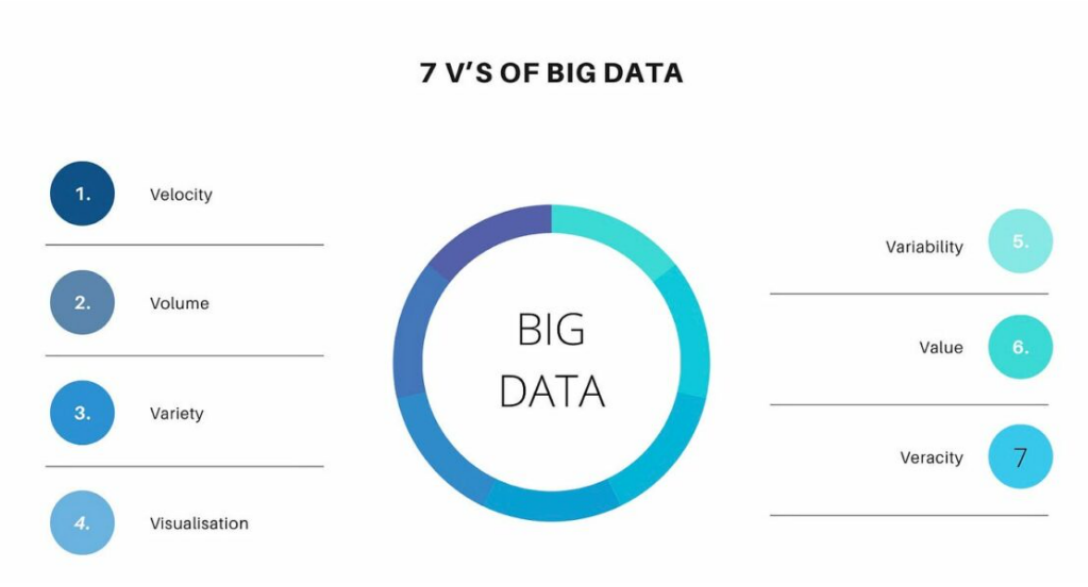

Hình 1.1 Các đặc điểm và tính chất quan trọng của Big Data

Dưới đây là các đặc trưng quan trọng của Big Data được trình bày chi tiết[1]:

1.1.1 Volume

Volume đề cập đến lượng dữ liệu khổng lồ được tạo ra và thu thập. Kích thước của Big Data thường vượt xa khả năng của các hệ thống truyền thống, được tính bằng

terabyte, petabyte, hoặc thậm chí exabyte. 1 petabyte tương đương 13,3 năm video HD. Các nguồn dữ liệu như mạng xã hội, thiết bị di động và IoT liên tục "bơm"dữ liệu.

Việc lưu trữ và quản lý khối lượng dữ liệu lớn này đòi hỏi các hệ thống lưu trữ phân tán như Hadoop Distributed File System hay còn gọi là HDFS và các dịch vụ lưu trữ đám mây. Các hệ thống này có khả năng mở rộng linh hoạt để đáp ứng nhu cầu lưu trữ ngày càng tăng. Thách thức không chỉ là lưu trữ, mà còn ở việc truy xuất và xử lý. Để truy vấn và phân tích, các công nghệ như MapReduce, Spark và các cơ sở dữ liệu NoSQL đã ra đời, cho phép phân tán việc xử lý dữ liệu trên nhiều máy tính, tăng tốc độ và giảm thời gian chờ đợi.

1.1.2 Velocity

Velocity đề cập đến tốc độ dữ liệu được tạo ra, thu thập, xử lý và phân tích. Trong nhiều lĩnh vực, dữ liệu cần được xử lý gần như ngay lập tức hoặc trong thời gian rất ngắn. Ví dụ điển hình bao gồm giao dịch chứng khoán, phát hiện gian lận thẻ tín dụng, hoặc dữ liệu từ cảm biến trên xe tự lái.

Để đáp ứng yêu cầu về tốc độ, các công nghệ như Apache Kafka, Apache Storm, Apache Flink và các nền tảng streaming analytics đã ra đời. Các công nghệ này cho phép xử lý dữ liệu liên tục thay vì xử lý theo lô batch processing, giúp giảm độ trễ đáng kể. Việc sử dụng các phần cứng chuyên dụng như GPU Graphics Processing Unit và TPU Tensor Processing Unit cũng góp phần tăng tốc độ xử lý. Tốc độ chính là yếu tố then chốt để biến dữ liệu lớn thành thông tin có giá trị, giúp đưa ra quyết định kịp thời.

1.1.3 Variety

Variety đề cập đến sự đa dạng về định dạng và loại dữ liệu. Big Data bao gồm dữ liệu có cấu trúc như bảng trong cơ sở dữ liệu quan hệ, dữ liệu bán cấu trúc như JSON, XML, và dữ liệu phi cấu trúc như văn bản, hình ảnh, âm thanh, video.

Trong thực tế, dữ liệu phi cấu trúc chiếm phần lớn trong Big Data. Để phân tích văn bản, chúng ta sử dụng Natural Language Processing NLP. Để phân tích hình ảnh, chúng ta sử dụng Computer Vision. Việc tích hợp và phân tích các loại dữ liệu đa dạng này là một thách thức lớn. Data Lake là một giải pháp lưu trữ cho phép lưu giữ dữ liệu ở dạng thô mà không cần xác định cấu trúc trước. Các công nghệ Big Data ra đời nhằm giải quyết bài toán xử lý các loại dữ liệu khác nhau, đòi hỏi những công cụ phù hợp cho

từng dạng dữ liệu.

1.1.4 Veracity

Veracity đề cập đến độ tin cậy, chính xác và chất lượng của dữ liệu. Trong thực tế, dữ liệu lớn thường không đầy đủ, không nhất quán, chứa nhiễu hoặc sai lệch. Nguồn gốc của dữ liệu không đáng tin cậy rất đa dạng, từ lỗi nhập liệu, lỗi thiết bị, cho đến hành vi gian lận.

Trước khi phân tích, cần thực hiện tiền xử lý dữ liệu. Các bước điển hình bao gồm: làm sạch dữ liệu để loại bỏ nhiễu, xử lý giá trị thiếu , chuẩn hóa, và tích hợp dữ liệu. Đảm bảo tính xác thực là vô cùng quan trọng để có được kết quả phân tích đáng tin cậy. Veracity đảm bảo rằng các quyết định được đưa ra dựa trên dữ liệu là chính xác. Đây là một quá trình liên tục, không phải một bước duy nhất.

1.1.5 Value

Value là mục tiêu cuối cùng và quan trọng nhất của Big Data. Dữ liệu lớn chỉ thực sự có giá trị khi chúng ta có thể trích xuất được những thông tin chi tiết có thể hành động, giúp cải thiện hoạt động, ra quyết định tốt hơn hoặc tạo ra lợi thế cạnh tranh. Value chính là yếu tố quyết định sự thành công của một dự án Big Data.

Việc tìm ra giá trị từ dữ liệu đòi hỏi sự kết hợp của nhiều kỹ năng: phân tích dữ liệu, trực quan hóa dữ liệu và kiến thức chuyên môn về lĩnh vực đang xét. Các nhà khoa học dữ liệu và các nhà phân tích kinh doanh đóng vai trò then chốt trong quá trình này. Nếu không tạo ra được giá trị, việc thu thập, lưu trữ và xử lý dữ liệu lớn trở nên vô nghĩa và lãng phí nguồn lực.

1.1.6 Variability

Ngoài 5V truyền thống, Variability là một đặc trưng quan trọng được bổ sung sau này. Variability đề cập đến sự thay đổi về ý nghĩa, cấu trúc và tốc độ của dữ liệu theo thời gian. Dữ liệu có thể thay đổi do nhiều yếu tố khác nhau, chẳng hạn như hành vi người dùng, môi trường kinh doanh hoặc cách thức dữ liệu được thu thập. Ý nghĩa của một từ có thể khác nhau tùy vào ngữ cảnh sử dụng.

Việc xử lý dữ liệu biến động đòi hỏi các hệ thống và kỹ thuật có khả năng thích ứng cao. Các hệ thống Big Data cần có cơ chế tự động phát hiện và xử lý các thay đổi. Ví dụ, một hệ thống phát hiện gian lận thẻ tín dụng cần liên tục cập nhật mô hình để thích

ứng với các thủ đoạn gian lận mới. Variability đòi hỏi các giải pháp phân tích linh hoạt, không cứng nhắc.

1.1.7 Visualization

Visualization là việc biểu diễn dữ liệu lớn một cách trực quan thông qua biểu đồ, đồ thị, dashboard và các hình thức trực quan khác. Việc này giúp con người dễ dàng nắm bắt thông tin, nhận ra xu hướng và các insight ẩn chứa bên trong dữ liệu. Trực quan hóa dữ liệu không chỉ giúp trình bày kết quả phân tích một cách dễ hiểu, mà còn hỗ trợ phát hiện các mẫu và xu hướng mà các phương pháp thống kê truyền thống có thể bỏ qua.

Với khối lượng dữ liệu khổng lồ, việc sử dụng các công cụ trực quan hóa chuyên dụng là vô cùng quan trọng. Các công cụ như Tableau, Power BI và các thư viện trong Python như Matplotlib, Seaborn giúp tạo ra các biểu đồ tương tác, đẹp mắt và dễ hiểu. Visualization đóng vai trò như một cầu nối giữa dữ liệu phức tạp và con người, giúp hỗ trợ ra quyết định và khám phá tri thức mới một cách hiệu quả.

1.2 Kiến trúc Big Data

Kiến trúc của Big Data bao gồm các thành phần chính sau:

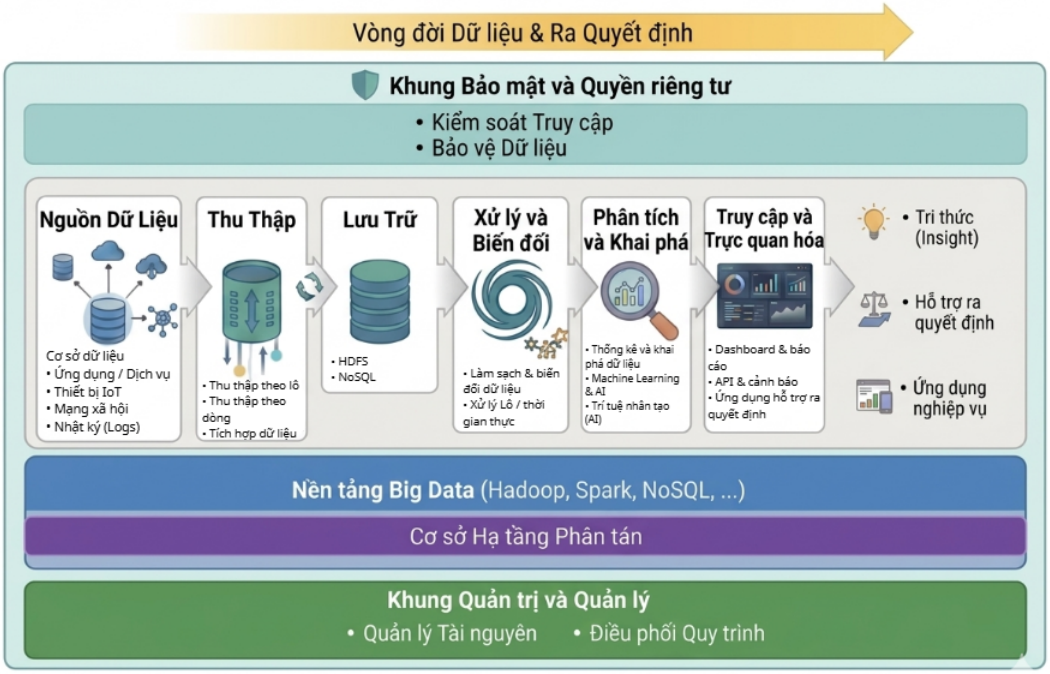

Hình 1.2 Caption

Để tối ưu hóa việc quản lý và phân tích, các tập dữ liệu khổng lồ thường được phân

loại dựa trên định dạng và cách thức lưu trữ. Việc hiểu rõ các loại hình này giúp doanh nghiệp lựa chọn đúng công cụ xử lý, từ đó tiết kiệm tối đa nguồn lực và thời gian.

Các loại dữ liệu trong Big Data:

- Dữ liệu có cấu trúc là loại dữ liệu có tổ chức rõ ràng, thường được lưu dưới dạng hàng và cột trong cơ sở dữ liệu quan hệ. Dữ liệu này có định dạng cố định, dễ lưu trữ, truy xuất và phân tích bằng các phương pháp truyền thống. Ví dụ gồm thông tin khách hàng, số điện thoại, lịch sử giao dịch ngân hàng và bảng lương nhân viên.

- Dữ liệu phi cấu trúc là dữ liệu không tuân theo mô hình định sẵn, không thể biểu diễn trực tiếp dưới dạng bảng. Đây là loại dữ liệu phổ biến nhất hiện nay và thường có khối lượng rất lớn, tăng trưởng nhanh, gây khó khăn cho việc lưu trữ và phân tích. Ví dụ gồm video, âm thanh, hình ảnh, bài đăng mạng xã hội và tệp PDF.

- Dữ liệu bán cấu trúc là dạng trung gian giữa dữ liệu có cấu trúc và phi cấu trúc. Dữ liệu này không nằm trong bảng cột cố định nhưng vẫn chứa các thẻ hoặc dấu hiệu định danh giúp hệ thống nhận biết và tổ chức thông tin. Ví dụ tiêu biểu là các tệp JSON, XML, HTML và tệp cấu hình hệ thống.

- Các nhóm dữ liệu mở rộng ngoài ba nhóm chính, Big Data còn bao gồm một số dạng dữ liệu đặc thù như dữ liệu chuỗi thời gian, biểu diễn sự thay đổi theo thời gian như giá cổ phiếu hoặc dữ liệu cảm biến; và dữ liệu không gian địa lý, bao gồm tọa độ GPS, bản đồ di chuyển và dữ liệu vệ tinh.

1.2.1 Thu thập dữ liệu

Thu thập dữ liệu là giai đoạn tiếp nhận dữ liệu từ nhiều nguồn khác nhau và đưa vào hệ thống để phục vụ lưu trữ, xử lý và phân tích. Trong môi trường Big Data, quá trình này cần bảo đảm khả năng tích hợp dữ liệu từ nhiều nguồn không đồng nhất, đồng thời hỗ trợ đồng bộ và chuẩn hóa dữ liệu đầu vào.

Quá trình thu thập không chỉ dừng lại ở việc lấy dữ liệu từ nguồn phát sinh mà còn bao gồm các thao tác như lọc dữ liệu, chuyển đổi định dạng, loại bỏ dữ liệu trùng lặp hoặc nhiễu và chuẩn bị dữ liệu cho các lớp phía sau. Trong thực tế, dữ liệu có thể được thu thập theo hai phương thức chính là thu thập theo lô và thu thập theo dòng. Thu thập theo lô phù hợp với các tác vụ xử lý định kỳ, trong khi thu thập theo dòng phù hợp với các hệ thống yêu cầu phản hồi nhanh gần thời gian thực.

1.2.2 Lưu trữ dữ liệu

Lưu trữ dữ liệu là lớp cốt lõi trong kiến trúc Big Data, có nhiệm vụ bảo quản và tổ chức khối lượng dữ liệu rất lớn được tạo ra liên tục từ nhiều nguồn khác nhau. Khác với các hệ thống truyền thống, lưu trữ trong Big Data cần bảo đảm khả năng mở rộng, phân tán và chịu lỗi cao nhằm đáp ứng yêu cầu về dung lượng và tốc độ truy xuất.

Trong thực tế, lớp này thường sử dụng các hệ thống tệp phân tán hoặc cơ sở dữ liệu NoSQL, chẳng hạn như HDFS và NoSQL. Các giải pháp này cho phép dữ liệu được phân bố trên nhiều nút khác nhau, qua đó nâng cao hiệu quả lưu trữ, hỗ trợ truy xuất linh hoạt và giảm nguy cơ mất mát dữ liệu khi xảy ra sự cố. Nhờ đó, lớp lưu trữ không chỉ đóng vai trò là nơi chứa dữ liệu mà còn là nền tảng cho các bước xử lý và phân tích phía sau.

1.2.3 Xử lý và biến đổi dữ liệu

Xử lý và biến đổi dữ liệu là giai đoạn chuyển đổi dữ liệu thô thành dữ liệu có ý nghĩa hơn để phục vụ phân tích. Ở giai đoạn này, dữ liệu thường được làm sạch, chuẩn hóa, tích hợp từ nhiều nguồn, biến đổi sang định dạng phù hợp và tổng hợp theo mục tiêu của từng bài toán cụ thể.

Trong hệ thống Big Data, quá trình xử lý thường được triển khai trên các nền tảng tính toán phân tán như Hadoop MapReduce hoặc Apache Spark nhằm tận dụng khả năng xử lý song song trên nhiều nút. Tương tự giai đoạn thu thập, xử lý dữ liệu cũng có thể diễn ra theo hai mô hình chính là xử lý theo lô và xử lý theo thời gian thực. Điều này giúp hệ thống vừa có thể xử lý các tập dữ liệu lớn theo chu kỳ, vừa có thể phản ứng nhanh với các dòng dữ liệu phát sinh liên tục.

1.2.4 Phân tích và khai phá dữ liệu

Phân tích và khai phá dữ liệu là giai đoạn khai thác thông tin có giá trị từ dữ liệu đã được xử lý. Đây là bước quan trọng vì mục tiêu cuối cùng của Big Data không chỉ là lưu trữ hay xử lý dữ liệu, mà là tạo ra tri thức hỗ trợ con người và tổ chức ra quyết định.

Quá trình này có thể bao gồm các kỹ thuật như thống kê dữ liệu, khai phá dữ liệu, học máy và trí tuệ nhân tạo. Thông qua các phương pháp này, hệ thống có thể phát hiện xu hướng, nhận diện mẫu ẩn, dự đoán hành vi, tối ưu hóa quy trình vận hành hoặc phát hiện các bất thường trong dữ liệu. Khi được triển khai hiệu quả, lớp phân tích và khai

phá sẽ chuyển dữ liệu đã xử lý thành thông tin có giá trị thực tiễn cao.

1.2.5 Truy cập và trực quan hóa

Sau khi dữ liệu được phân tích, kết quả cần được cung cấp cho người dùng hoặc các hệ thống khác thông qua lớp truy cập và trực quan hóa. Thành phần này cho phép người dùng tiếp cận kết quả dưới các hình thức như bảng điều khiển, báo cáo, giao diện API, hệ thống cảnh báo hoặc các ứng dụng hỗ trợ ra quyết định.

Vai trò của lớp này là biến các kết quả phân tích phức tạp thành những dạng thông tin trực quan, dễ hiểu và dễ khai thác hơn. Thay vì làm việc trực tiếp với dữ liệu thô hoặc các mô hình phân tích, người dùng có thể tiếp cận thông tin thông qua biểu đồ, dashboard, báo cáo tổng hợp hoặc cảnh báo tự động. Đây cũng là lớp kết nối trực tiếp giữa hệ thống Big Data với các ứng dụng nghiệp vụ trong thực tế.

1.2.6 Tri thức, hỗ trợ ra quyết định và ứng dụng nghiệp vụ

Đầu ra cuối cùng của kiến trúc Big Data không chỉ là dữ liệu đã được xử lý, mà là tri thức có thể sử dụng trong thực tiễn. Từ các kết quả phân tích và trực quan hóa, hệ thống hỗ trợ nhà quản lý hoặc người dùng đưa ra quyết định nhanh chóng, chính xác và dựa trên dữ liệu.

Bên cạnh đó, các kết quả này còn có thể được tích hợp vào các ứng dụng nghiệp vụ cụ thể như dự báo nhu cầu, phát hiện gian lận, gợi ý sản phẩm, giám sát hoạt động hoặc tối ưu hóa vận hành. Vì vậy, giá trị thực sự của Big Data được thể hiện ở khả năng chuyển hóa dữ liệu thành tri thức và tri thức thành hành động.

1.2.7 Bảo mật và quản trị hệ thống

Bảo mật và quản trị hệ thống là lớp xuyên suốt toàn bộ kiến trúc Big Data. Trong môi trường dữ liệu lớn, dữ liệu thường có giá trị cao và có thể chứa nhiều thông tin nhạy cảm, do đó việc kiểm soát truy cập, bảo vệ dữ liệu và bảo đảm quyền riêng tư là yêu cầu rất quan trọng.

Bên cạnh đó, quản trị hệ thống tập trung vào việc quản lý tài nguyên, theo dõi hiệu năng, giám sát hoạt động của các thành phần trong hệ thống và điều phối quy trình xử lý dữ liệu. Lớp này không tồn tại tách biệt ở cuối pipeline mà bao phủ toàn bộ các giai đoạn từ nguồn dữ liệu, thu thập, lưu trữ, xử lý, phân tích cho đến truy cập và khai thác kết quả.

1.3 Ứng dụng của Big Data trong các lĩnh vực

- Ngành ngân hàng và tài chính: Big Data giúp các ngân hàng và tổ chức tài chính quản lý dữ liệu khách hàng hiệu quả hơn, đồng thời giảm thiểu rủi ro, phát hiện gian lận và bảo đảm tuân thủ quy định pháp luật. Ngoài ra, dữ liệu lớn còn hỗ trợ xác định vị trí phù hợp để mở chi nhánh, dự đoán nhu cầu tiền mặt tại các điểm giao dịch, nâng cao độ chính xác của chấm điểm tín dụng và đẩy nhanh quá trình phê duyệt khoản vay.

- Giáo dục: Trong giáo dục, Big Data hỗ trợ cá nhân hóa lộ trình học tập thông qua việc phân tích lịch sử tương tác, thời gian làm bài và kết quả kiểm tra của người học. Nhờ đó, hệ thống có thể nhận diện các nội dung mà học viên còn yếu, đưa ra gợi ý học tập phù hợp, nâng cao hiệu quả đào tạo và giảm tỷ lệ bỏ học.

- Thương mại điện tử và bán lẻ: Big Data được ứng dụng mạnh mẽ trong các hệ thống gợi ý sản phẩm, giúp doanh nghiệp phân tích hành vi tìm kiếm và mua sắm của khách hàng để cá nhân hóa trải nghiệm. Bên cạnh đó, dữ liệu lớn còn hỗ trợ tối ưu chuỗi cung ứng, dự báo nhu cầu thị trường và quản lý hàng tồn kho hiệu quả hơn.

- Y tế và chăm sóc sức khỏe: Trong lĩnh vực y tế, Big Data hỗ trợ quản lý hồ sơ sức khỏe điện tử, theo dõi tình trạng bệnh nhân, hỗ trợ chẩn đoán sớm và nâng cao chất lượng chăm sóc sức khỏe. Dữ liệu từ các thiết bị thông minh và ứng dụng di động còn giúp giám sát bệnh nhân từ xa, cảnh báo nguy cơ dịch bệnh và hỗ trợ cơ quan y tế đưa ra biện pháp xử lý kịp thời.

- Digital Marketing và truyền thông: Big Data giúp doanh nghiệp nhắm mục tiêu khách hàng chính xác hơn dựa trên nhân khẩu học, sở thích và hành vi thực tế của người dùng. Điều này góp phần tối ưu chi phí quảng cáo, nâng cao hiệu quả chiến dịch truyền thông và cải thiện trải nghiệm khách hàng với các nội dung phù hợp hơn.

- Giao thông vận tải: Trong giao thông vận tải, Big Data hỗ trợ giám sát tuyến đường, tối ưu hóa lộ trình, quản lý phương tiện và cải thiện hiệu quả vận hành. Đồng thời, dữ liệu lớn còn giúp người dùng nắm bắt thông tin di chuyển chính xác hơn, hỗ trợ lập kế hoạch đi lại và nâng cao chất lượng dịch vụ giao thông.

- Dịch vụ khách hàng: Big Data giúp doanh nghiệp hiểu rõ hơn nhu cầu, hành vi và mức độ quan tâm của khách hàng. Từ đó, doanh nghiệp có thể cải thiện chất lượng phục vụ, thiết kế sản phẩm hoặc dịch vụ phù hợp hơn, đồng thời xây dựng các chiến lược tiếp

thị hiệu quả để nâng cao năng lực cạnh tranh.

1.4 Các công nghệ xử lý dữ liệu lớn

Hệ sinh thái công nghệ xử lý dữ liệu lớn Big Data bao gồm nhiều công cụ và framework khác nhau, mỗi công nghệ được tối ưu hóa cho các tầng xử lý và yêu cầu cụ thể. Nhìn chung, các công nghệ này có thể được phân chia theo chức năng như sau:

- Công nghệ lưu trữ phân tán Distributed Storage: Đây là nền tảng để lưu trữ khối lượng dữ liệu khổng lồ trên nhiều máy chủ. Hadoop Distributed File System HDFS là công nghệ tiên phong, cho phép lưu trữ dữ liệu phi cấu trúc với chi phí thấp trên các cụm máy chủ thông thường. Bên cạnh đó, các hệ thống cơ sở dữ liệu NoSQL như HBase mô hình column-family, MongoDB mô hình tài liệu, Cassandra và Redis cũng được sử dụng rộng rãi để đáp ứng nhu cầu truy xuất dữ liệu phi cấu trúc hoặc bán cấu trúc với độ trễ thấp.

- Công nghệ tính toán phân tán Distributed Computing: Đây là thành phần cốt lõi để xử lý và biến đổi dữ liệu. MapReduce là mô hình lập trình cổ điển trong hệ sinh thái Hadoop, phù hợp cho các tác vụ xử lý theo lô batch processing. Tuy nhiên, Apache Spark đã trở thành tiêu chuẩn thực tế nhờ khả năng xử lý trong bộ nhớ in-memory, giúp tăng tốc độ xử lý lên gấp nhiều lần so với MapReduce, đồng thời hỗ trợ đa dạng các loại hình xử lý như batch, SQL, streaming và machine learning.

- Công nghệ xử lý luồng dữ liệu Stream Processing: Khác với xử lý lô, xử lý luồng cho phép phân tích dữ liệu ngay khi nó được sinh ra. Apache Kafka là một nền tảng phân phối sự kiện event streaming platform được dùng phổ biến để xây dựng các đường ống dữ liệu thời gian thực nhờ khả năng xử lý thông lượng cao và chịu lỗi tốt. Apache Flink nổi bật với khả năng xử lý luồng thực sự true streaming với độ trễ cực thấp và đảm bảo tính chính xác. Ngoài ra, Spark Streaming cũng là một lựa chọn phổ biến, mặc dù nó hoạt động dựa trên mô hình vi-batch micro-batch.

- Công nghệ phân tích và truy vấn Analysis and Query: Các công cụ này cung cấp giao diện thân thiện thường là SQL để khai thác dữ liệu đã được lưu trữ và xử lý. Apache Hive cho phép chạy truy vấn SQL trên dữ liệu trong HDFS, giúp các nhà phân tích dễ dàng tiếp cận mà không cần viết mã MapReduce phức tạp. Spark SQL là một thành phần của Spark, tối ưu hóa truy vấn SQL trên DataFrame. Gần đây, các cơ sở dữ liệu OLAP

Online Analytical Processing thế hệ mới như ClickHouse, Apache Druid đang nổi lên nhờ khả năng xử lý truy vấn phân tích với tốc độ cực nhanh trên dữ liệu lớn.

- Công nghệ điều phối và quản lý Orchestration and Management: Các hệ thống như Apache Airflow, Apache Oozie đóng vai trò lập lịch, giám sát và điều phối các luồng công việc workflow phức tạp giữa nhiều tác vụ xử lý dữ liệu khác nhau. Về quản lý tài nguyên, YARN Yet Another Resource Negotiator và Kubernetes giúp quản lý và phân bổ tài nguyên CPU, RAM cho các ứng dụng trong cụm máy chủ.

CHƯƠNG 2: GIỚI THIỆU APACHE SPARK

2.1 Kiến trúc Spark

2.2 So sánh Spark với MapReduce

2.3 Các thành phần quan trọng trong Spark

2.3.1 Spark Core (RDD, DataFrame, Dataset)
2.3.2 Spark SQL
2.3.3 Spark Streaming
2.3.4 Spark GraphX
2.3.5 Spark MLlib

CHƯƠNG 3: PHÂN TÍCH VÀ KHÁM PHÁ DỮ LIỆU

3.1 Môi trường thực nghiệm

Các thí nghiệm trong đồ án được thực hiện trên máy tính cá nhân MacBook Air sử dụng chip Apple M3, bộ nhớ RAM 16GB, với môi trường lập trình Python phiên bản 3.11.15. Cấu hình này đáp ứng tốt các yêu cầu xử lý dữ liệu, phân tích khám phá dữ liệu và xây dựng mô hình trong phạm vi đồ án.

Về công cụ phần mềm, đề tài sử dụng Apache Spark thông qua thư viện PySpark để xử lý dữ liệu phân tán, kết hợp với các thư viện hỗ trợ như Pandas, NumPy và Matplotlib nhằm phục vụ cho việc tính toán thống kê, xử lý dữ liệu cục bộ và trực quan hóa kết quả. Toàn bộ quá trình thực nghiệm được triển khai trong môi trường Jupyter Notebook, giúp thuận tiện cho việc tổ chức mã nguồn, theo dõi kết quả trung gian và trình bày các bước thực hiện.

3.2 Dữ liệu thực nghiệm

Bộ dữ liệu được sử dụng trong đồ án là tập dữ liệu mô phỏng các giao dịch thẻ tín dụng, bao gồm cả giao dịch hợp lệ và giao dịch gian lận. Dữ liệu phản ánh các giao dịch phát sinh trong khoảng thời gian từ ngày 01/01/2019 đến ngày 31/12/2020. Bộ dữ liệu bao gồm thông tin giao dịch của 1000 khách hàng thực hiện giao dịch với khoảng 800 merchant khác nhau.

Bộ dữ liệu này được tạo ra từ công cụ mô phỏng Sparkov Data Generation do Brandon Harris phát triển. Công cụ mô phỏng sử dụng các danh sách định nghĩa sẵn về khách hàng, merchant và các nhóm danh mục giao dịch. Dựa trên các hồ sơ mô phỏng khác nhau, chẳng hạn như giới tính, độ tuổi, khu vực sinh sống và hành vi chi tiêu, hệ thống sẽ sinh ra các giao dịch với số lượng và giá trị giao dịch khác nhau theo các phân phối thống kê đã được thiết lập trước.

Cụ thể, trong quá trình mô phỏng, các giao dịch được tạo ra dựa trên các tham số như số lượng giao dịch tối thiểu và tối đa trong ngày, phân bố giao dịch theo ngày trong tuần, cũng như các đặc trưng phân phối chuẩn của số tiền giao dịch trong từng nhóm danh mục. Thư viện `faker` trong Python được sử dụng để sinh dữ liệu giả lập, từ đó tạo

nên các bản ghi giao dịch mang tính mô phỏng nhưng vẫn phản ánh tương đối hợp lý các hành vi giao dịch trong thực tế.

Trong bộ dữ liệu này, các giao dịch từ nhiều nhóm hồ sơ khác nhau đã được tổng hợp lại nhằm tạo ra một tập dữ liệu đa dạng và có tính đại diện cao hơn. Mặc dù đây không phải là dữ liệu giao dịch thực tế từ ngân hàng hay tổ chức tài chính, bộ dữ liệu vẫn phù hợp cho mục đích nghiên cứu, thử nghiệm và đánh giá các phương pháp phát hiện gian lận trong môi trường dữ liệu lớn.

3.3 Kiểm tra chất lượng dữ liệu

Sau khi tiến hành nạp bộ dữ liệu vào môi trường Apache Spark, nhóm thực hiện bước kiểm tra chất lượng dữ liệu nhằm đánh giá mức độ đầy đủ, nhất quán và khả năng sử dụng của dữ liệu trước khi thực hiện các phân tích sâu hơn. Việc kiểm tra này tập trung vào ba nội dung chính, bao gồm: cấu trúc dữ liệu, giá trị thiếu và bản ghi trùng lặp. Trước hết, về quy mô dữ liệu, tập huấn luyện gồm 1.296.675 dòng với 23 cột, trong khi tập kiểm tra gồm 555.719 dòng với 23 cột. Tổng cộng, toàn bộ bộ dữ liệu có 1.852.394 bản ghi. Kết quả này cho thấy dữ liệu có quy mô tương đối lớn, phù hợp với bài toán xử lý dữ liệu lớn và phát hiện gian lận giao dịch bằng Apache Spark.

Về cấu trúc dữ liệu, bộ dữ liệu bao gồm các nhóm thuộc tính mô tả thông tin giao dịch, thông tin khách hàng, vị trí địa lý, thời gian giao dịch và nhãn gian lận. Cụ thể, các cột như `trans_date_trans_time`, `amt`, `merchant`, `category`, `lat`, `long`, `merch_lat`, `merch_long` và `is_fraud` là những thuộc tính có vai trò quan trọng trong quá trình phân tích và xây dựng mô hình. Ngoài ra, một số cột như `_c0`, `first`, `last`, `street` hay `trans_num` chủ yếu mang ý nghĩa định danh hoặc mô tả thông tin cá nhân, do đó sẽ được xem xét loại bỏ hoặc xử lý ở giai đoạn tiền xử lý dữ liệu. Tiếp theo, kết quả kiểm tra giá trị thiếu cho thấy tất cả 23 cột trong cả hai tập dữ liệu đều không chứa giá trị thiếu. Nói cách khác, số lượng giá trị null ở mỗi cột đều bằng 0. Đây là một ưu điểm quan trọng của bộ dữ liệu, giúp giảm bớt độ phức tạp trong giai đoạn tiền xử lý do không cần áp dụng thêm các phương pháp thay thế hoặc loại bỏ dữ liệu thiếu.

Bên cạnh đó, nhóm cũng tiến hành kiểm tra tính duy nhất của các bản ghi giao dịch thông qua trường `trans_num`, vốn được xem là mã định danh duy nhất cho mỗi giao dịch. Kết quả cho thấy trong tập huấn luyện, số lượng giá trị phân biệt của `trans_num` đúng

bằng tổng số dòng, tức là 1.296.675, không xuất hiện bản ghi trùng lặp. Tương tự, trong tập kiểm tra, số lượng giá trị phân biệt của `trans_num` là 555.719, cũng trùng với tổng số dòng của tập dữ liệu. Điều này cho thấy không tồn tại hiện tượng trùng lặp giao dịch trong cả hai tập dữ liệu. Từ các kết quả trên có thể nhận thấy bộ dữ liệu có chất lượng tốt về mặt cấu trúc và tính toàn vẹn dữ liệu. Dữ liệu không chứa giá trị thiếu, không có bản ghi giao dịch trùng lặp và có đầy đủ các thuộc tính cần thiết để phục vụ cho bài toán phát hiện gian lận. Đây là cơ sở thuận lợi để tiếp tục thực hiện các bước phân tích khám phá dữ liệu và xây dựng mô hình ở các phần tiếp theo.

3.4 Phân bố nhãn và thống kê mô tả

Trong bộ dữ liệu sử dụng cho bài toán phát hiện gian lận thẻ tín dụng, biến mục tiêu `is_fraud` được sử dụng để biểu diễn nhãn của mỗi giao dịch, trong đó giá trị 0 tương ứng với giao dịch hợp lệ và giá trị 1 tương ứng với giao dịch gian lận. Việc khảo sát phân bố nhãn là cần thiết nhằm đánh giá mức độ cân bằng của dữ liệu trước khi tiến hành xây dựng mô hình. Kết quả thống kê cho thấy tập huấn luyện có 1.289.169 giao dịch hợp lệ, chiếm 99,421%, và 7.506 giao dịch gian lận, chiếm 0,579%. Tương tự, trong tập kiểm tra có 553.574 giao dịch hợp lệ, chiếm 99,614%, và 2.145 giao dịch gian lận, chiếm 0,386%. Như vậy, tỷ lệ giao dịch gian lận trong cả hai tập đều rất nhỏ so với số lượng giao dịch hợp lệ.

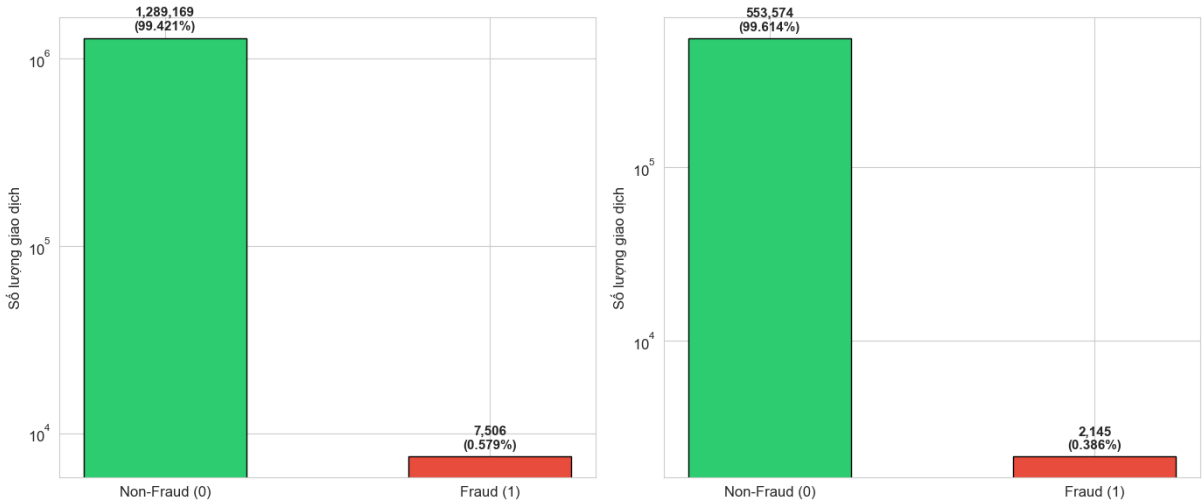

Hình 3.3 Phân bố nhãn giao dịch trong tập huấn luyện và tập kiểm tra

Từ Hình 3.3 có thể thấy bộ dữ liệu có mức độ mất cân bằng lớp rất cao. Đây là đặc

điểm phổ biến trong các bài toán phát hiện gian lận thực tế, khi số lượng giao dịch bất thường thường chỉ chiếm một tỷ lệ rất nhỏ trong tổng số giao dịch. Đặc điểm này cho thấy việc đánh giá mô hình ở các bước tiếp theo không thể chỉ dựa vào độ chính xác tổng thể, mà cần xem xét thêm các chỉ số như Precision, Recall, F1-score, AUC-ROC và đặc biệt là AUC-PR.

Trong khi phân bố nhãn được xem xét trên cả tập huấn luyện và tập kiểm tra nhằm đánh giá mức độ mất cân bằng dữ liệu giữa hai tập, các thống kê mô tả chi tiết cho biến `amt` được thực hiện chủ yếu trên tập huấn luyện để phục vụ cho quá trình phân tích đặc trưng và xây dựng mô hình ở các bước tiếp theo. Trong đó, biến `amt` được lựa chọn làm trọng tâm do đây là thuộc tính phản ánh trực tiếp giá trị của giao dịch, có ý nghĩa rõ ràng trong bài toán phát hiện gian lận và cho thấy sự khác biệt đáng kể giữa hai nhóm giao dịch hợp lệ và gian lận. Kết quả thống kê trên tập huấn luyện được trình bày trong Bảng 3.1. Giá trị nhỏ nhất của `amt` là 1,0 USD, giá trị lớn nhất là 28.948,9 USD, giá trị trung bình là 70,35 USD, độ lệch chuẩn là 160,32 USD và trung vị là 47,51 USD. Các chỉ số này cho thấy phân bố của số tiền giao dịch có độ phân tán lớn và tồn tại hiện tượng lệch phải do xuất hiện một số giao dịch có giá trị rất cao.

Bảng 3.1: Thống kê mô tả biến số tiền giao dịch `amt` trong tập huấn luyện

Count	Min	Max	Mean	Std	Median
1.296.675	1,0	28.948,9	70,35	160,32	47,51

Để đánh giá rõ hơn vai trò của biến `amt`, nhóm tiến hành so sánh thống kê số tiền giao dịch giữa hai nhóm nhãn. Kết quả được trình bày trong Bảng 3.2. Đối với các giao dịch hợp lệ, giá trị trung bình của `amt` là 67,67 USD và trung vị là 47,29 USD. Trong khi đó, ở nhóm giao dịch gian lận, giá trị trung bình đạt 531,32 USD và trung vị là 394,72 USD, cao hơn đáng kể so với nhóm giao dịch hợp lệ. Đồng thời, độ lệch chuẩn của nhóm giao dịch gian lận cũng lớn hơn, phản ánh mức độ biến động mạnh hơn của số tiền trong nhóm này.

Bảng 3.2: Thống kê số tiền giao dịch theo nhãn `is_fraud`

is_fraud	Count	Min	Max	Mean	Std	Median
0	1.289.169	1,0	28.948,9	67,67	154,01	47,29
1	7.506	1,06	1.376,04	531,32	390,56	394,72

Để trực quan hóa sự khác biệt này, nhóm sử dụng biểu đồ hộp của biến `amt` theo từng nhãn trên thang đo logarit, như thể hiện ở Hình 3.4. Việc sử dụng thang logarit giúp thể hiện rõ hơn phân bố của dữ liệu trong bối cảnh số tiền giao dịch có độ lệch lớn và xuất hiện nhiều giá trị ngoại lệ.

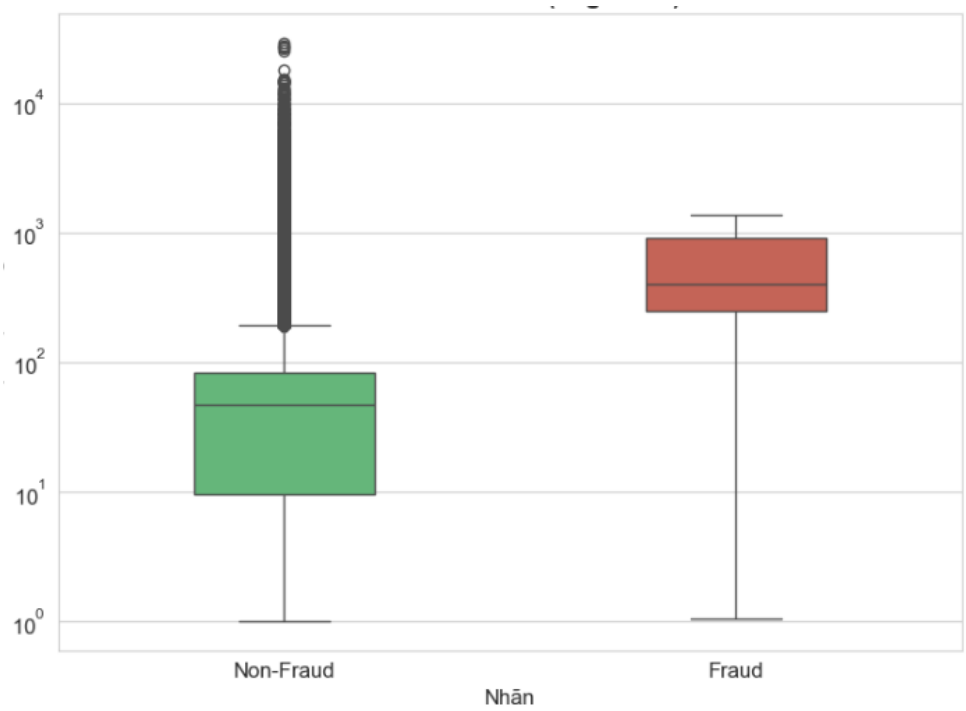

Hình 3.4 Phân bố số tiền giao dịch theo nhãn trên thang đo logarit

Từ Hình 3.4 có thể thấy phân bố số tiền giao dịch của hai nhóm có sự khác biệt rõ rệt. Nhóm giao dịch gian lận có trung vị và khoảng tứ phân vị cao hơn đáng kể so với nhóm giao dịch hợp lệ. Điều này cho thấy biến `amt` có khả năng phân biệt tốt giữa hai nhóm giao dịch, từ đó có tiềm năng trở thành một đặc trưng quan trọng trong quá trình xây dựng mô hình phát hiện gian lận ở các phần tiếp theo.

3.5 Phân tích đa chiều với Spark SQL

Nhằm làm rõ hơn đặc điểm của các giao dịch gian lận trong bộ dữ liệu, nhóm tiến hành khai thác dữ liệu trên nhiều chiều thông tin khác nhau bằng Spark SQL, bao gồm danh mục giao dịch, merchant, giới tính và độ tuổi khách hàng.

3.5.1 Phân tích gian lận theo danh mục giao dịch

Trước hết, nhóm tiến hành phân tích số lượng giao dịch gian lận và tỷ lệ gian lận theo từng danh mục giao dịch (`category`). Kết quả thống kê cho thấy mức độ gian lận không phân bố đồng đều giữa các nhóm danh mục. Xét theo số lượng giao dịch gian lận, các danh mục nổi bật bao gồm `grocery_pos`, `shopping_net`, `misc_net`, `shopping_pos` và `gas_transport`. Trong đó, `grocery_pos` là nhóm ghi nhận số lượng giao dịch gian lận lớn nhất.

Khi xem xét theo tỷ lệ gian lận, thứ tự các danh mục có sự thay đổi đáng kể. Cụ thể, `shopping_net` là nhóm có mức rủi ro cao nhất với tỷ lệ fraud đạt 1,76%, tiếp theo là `misc_net` với 1,45% và `grocery_pos` với 1,41%. Bên cạnh đó, `shopping_pos` và `gas_transport` cũng ghi nhận tỷ lệ gian lận tương đối cao, lần lượt ở mức 0,72% và 0,47%.

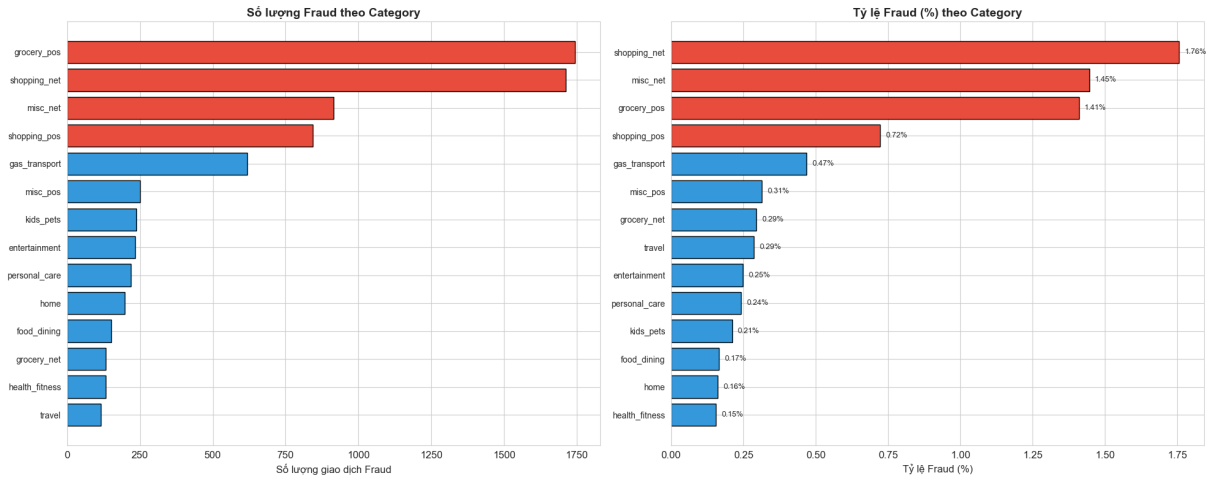

Hình 3.5 Số lượng và tỷ lệ giao dịch gian lận theo danh mục giao dịch

Biểu đồ trong Hình 3.5 cho thấy số lượng giao dịch gian lận và tỷ lệ gian lận không hoàn toàn đồng nhất giữa các danh mục. Một số nhóm có số vụ fraud lớn nhưng chưa chắc là nhóm có mức rủi ro cao nhất, điển hình là `grocery_pos`. Trái lại, `shopping_net` không đứng đầu về số lượng nhưng lại dẫn đầu về tỷ lệ gian lận. Sự khác biệt này cho

thấy loại hình giao dịch có liên hệ đáng kể với khả năng xảy ra gian lận, đồng thời gợi ý rằng biến `category` là một đặc trưng quan trọng cần được giữ lại trong giai đoạn xây dựng mô hình.

3.5.2 Phân tích gian lận theo merchant

Tiếp theo, nhóm thực hiện thống kê top 10 merchant có số lượng giao dịch gian lận nhiều nhất trong tập huấn luyện. Kết quả cho thấy một số merchant xuất hiện với tần suất đáng chú ý trong các giao dịch bị gắn nhãn gian lận. Cụ thể, `fraud_Rau and Sons` là merchant có số lượng giao dịch gian lận lớn nhất với 49 trường hợp, tiếp theo là `fraud_Kozey-Boehm` và `fraud_Cormier LLC` với cùng 48 trường hợp. Các merchant còn lại trong danh sách cũng ghi nhận từ 42 đến 47 giao dịch gian lận.

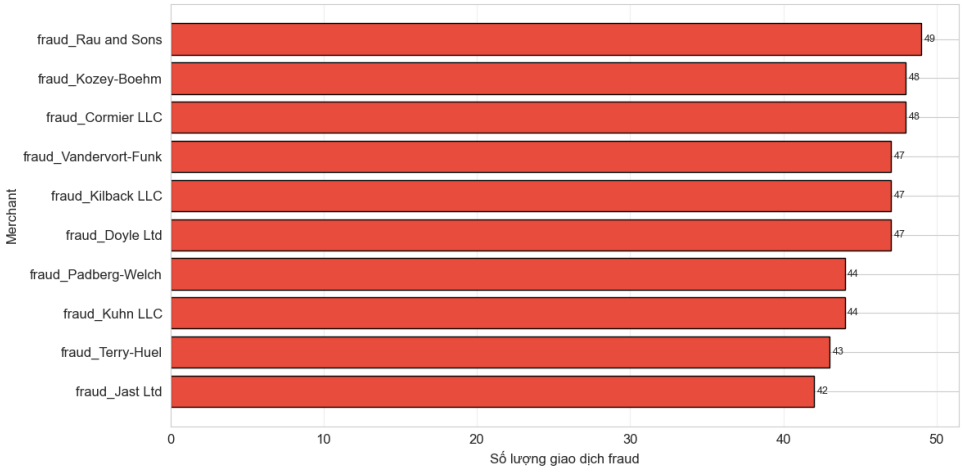

Hình 3.6 Top 10 merchant có số lượng giao dịch gian lận nhiều nhất

Hình 3.6 thể hiện rõ số lượng giao dịch gian lận giữa các merchant thuộc nhóm top 10 không chênh lệch quá lớn, tuy nhiên vẫn có một vài merchant nổi bật hơn phần còn lại. Điều này cho thấy đặc trưng `merchant` có khả năng mang thông tin hữu ích trong bài toán phát hiện gian lận. Đồng thời, kết quả này cũng tạo cơ sở cho các bước tiếp theo khi xem xét merchant như một đặc trưng đầu vào của mô hình và như một đỉnh trong đồ thị giao dịch customer–merchant.

3.5.3 Phân tích gian lận theo giới tính

Một khía cạnh khác được xem xét là sự khác biệt về số lượng và tỷ lệ giao dịch gian lận theo giới tính khách hàng thông qua thuộc tính `gender`. Kết quả thống kê cho thấy số lượng giao dịch gian lận giữa hai nhóm giới tính không chênh lệch nhiều. Cụ thể,

nhóm khách hàng nam ghi nhận 3.771 giao dịch gian lận, trong khi nhóm khách hàng nữ có 3.735 giao dịch gian lận.

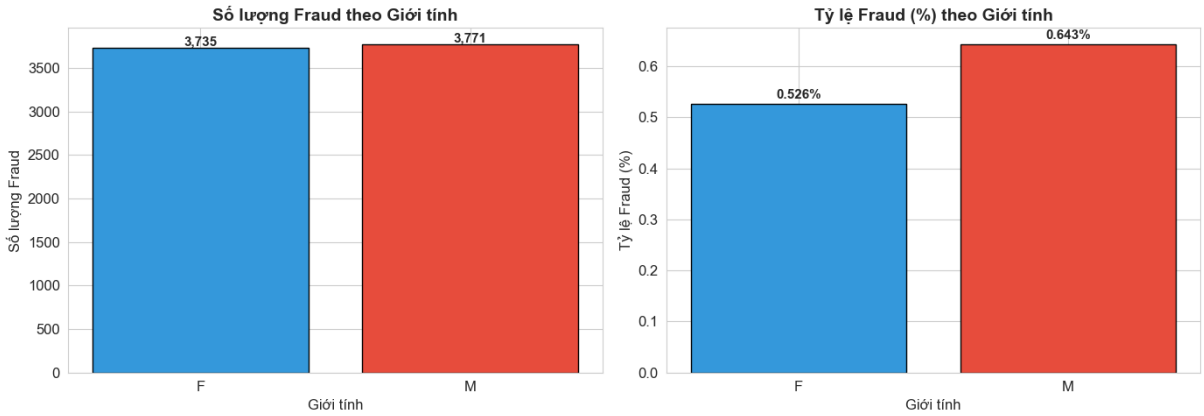

Hình 3.7 Số lượng và tỷ lệ giao dịch gian lận theo giới tính

Xét theo tỷ lệ, nhóm nam có mức fraud là 0,643%, cao hơn so với nhóm nữ ở mức 0,526%. Mặc dù chênh lệch giữa hai nhóm không quá lớn, kết quả này vẫn gợi ý rằng giới tính có thể mang một mức độ thông tin nhất định đối với bài toán phát hiện gian lận. Tuy nhiên, đây chưa phải là yếu tố đủ mạnh để phân tách rõ ràng hai nhóm giao dịch, do đó cần được xem xét kết hợp với các đặc trưng khác trong quá trình xây dựng mô hình.

3.5.4 Phân tích gian lận theo nhóm tuổi

Bên cạnh đó độ tuổi cũng là một yếu tố quan trọng cần được xem xet. Xét theo độ tuổi khách hàng, số lượng và tỷ lệ giao dịch gian lận được khảo sát trên các nhóm tuổi tính từ thuộc tính `dob`.

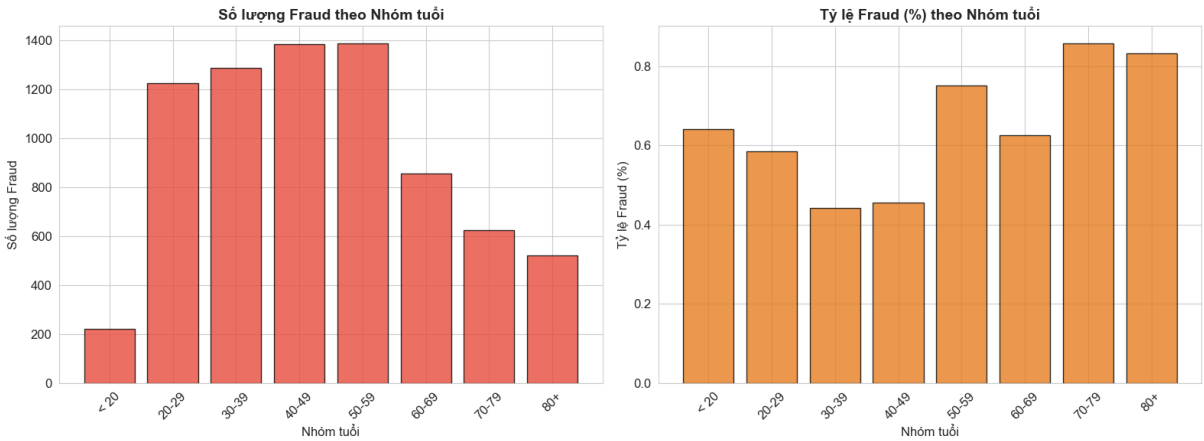

Hình 3.8 Số lượng và tỷ lệ giao dịch gian lận theo nhóm tuổi

Khi xem xét theo tỷ lệ, xu hướng phân bố có sự thay đổi nhất định. Các nhóm tuổi cao hơn lại ghi nhận tỷ lệ gian lận lớn hơn, trong đó nhóm 70–79 có tỷ lệ cao nhất, xấp xỉ 0,86%, tiếp theo là nhóm 80+ với khoảng 0,83%. Nhóm 50–59 cũng có mức fraud tương đối cao, khoảng 0,75%. Ngược lại, các nhóm 30–39 và 40–49 có tỷ lệ gian lận thấp hơn, lần lượt vào khoảng 0,44% và 0,45%. Những kết quả này cho thấy số lượng giao dịch gian lận và tỷ lệ gian lận không hoàn toàn đồng biến giữa các nhóm tuổi. Một số nhóm có nhiều giao dịch gian lận do tổng số giao dịch lớn, nhưng chưa chắc là nhóm có mức rủi ro cao nhất. Vì vậy, độ tuổi là một đặc trưng đáng chú ý và có thể mang lại thông tin bổ sung cho bài toán phát hiện gian lận khi được kết hợp với các biến khác.

3.5.5 Phân tích gian lận theo thời gian

Yếu tố thời gian cũng cho thấy nhiều khác biệt đáng chú ý trong phân bố giao dịch gian lận. Để làm rõ đặc điểm này, dữ liệu được phân tích theo ba chiều thời gian gồm giờ trong ngày, ngày trong tuần và tháng trong năm. Trước hết, khi xét theo giờ trong ngày, số lượng và tỷ lệ giao dịch gian lận không phân bố đồng đều giữa các khung giờ. Các giao dịch gian lận xuất hiện nhiều nhất vào khoảng 22 giờ và 23 giờ, với số lượng gần 1.900 trường hợp ở mỗi mốc thời gian. Đồng thời, tỷ lệ gian lận tại hai khung giờ này cũng tăng vọt, xấp xỉ 2,9%, cao hơn đáng kể so với phần lớn các khung giờ còn lại. Ngoài ra, khoảng thời gian từ 0 giờ đến 3 giờ sáng cũng ghi nhận mức fraud tương đối cao, dao động quanh 1,4% đến 1,5%. Trong khi đó, từ 4 giờ đến 21 giờ, tỷ lệ gian lận duy trì ở mức thấp hơn nhiều, chủ yếu quanh khoảng 0,1%.

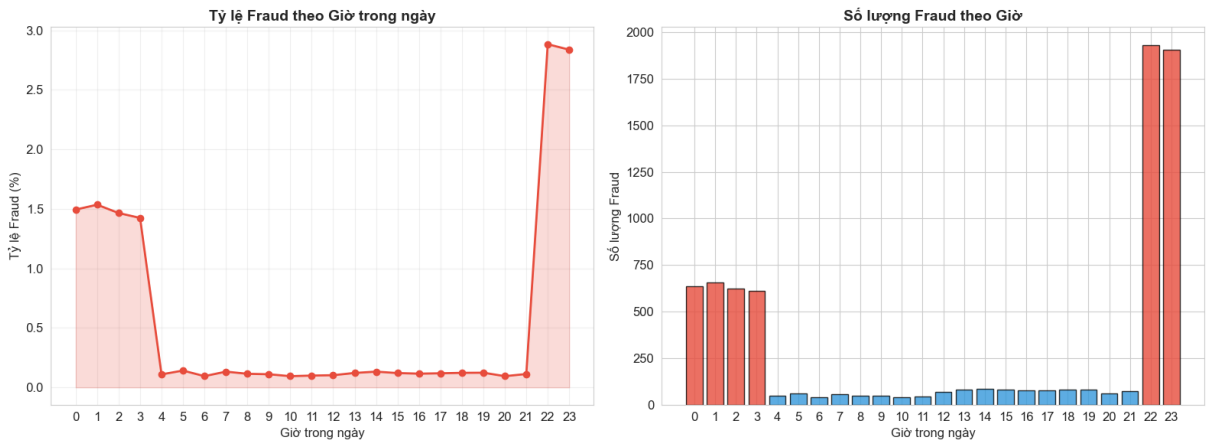

Hình 3.9 Số lượng và tỷ lệ giao dịch gian lận theo giờ trong ngày

Sự phân bố này cho thấy các giao dịch gian lận trong bộ dữ liệu có xu hướng tập

trung vào ban đêm, đặc biệt là cuối ngày. Điều này gợi ý rằng đặc trưng thời gian theo giờ có thể mang lại giá trị phân biệt đáng kể trong bài toán phát hiện gian lận.

Xét theo ngày trong tuần, tỷ lệ gian lận có sự biến động nhưng không quá cực đoan như theo giờ. Mức thấp nhất được ghi nhận vào thứ Hai với khoảng 0,465%, trong khi mức cao nhất xuất hiện vào thứ Sáu với khoảng 0,709%. Các ngày còn lại dao động trong khoảng từ 0,485% đến 0,684%, cho thấy giao dịch gian lận có xu hướng tăng dần về cuối tuần.

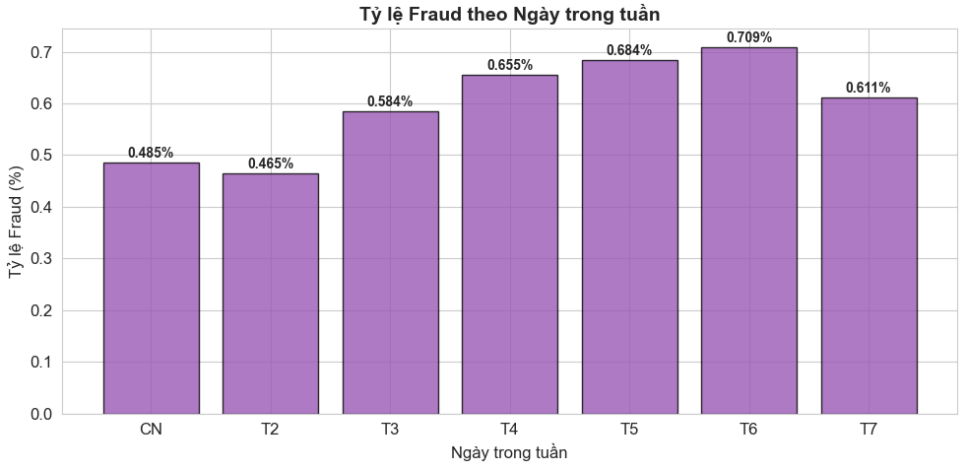

Hình 3.10 Tỷ lệ giao dịch gian lận theo ngày trong tuần

Kết quả này phản ánh rằng yếu tố ngày trong tuần có thể ảnh hưởng nhất định đến hành vi giao dịch, dù mức độ tác động không mạnh bằng đặc trưng giờ trong ngày.

Ở quy mô theo tháng, tỷ lệ gian lận thay đổi tương đối rõ qua các thời điểm trong năm. Tháng 2 là giai đoạn có tỷ lệ gian lận cao nhất với khoảng 0,873%, tiếp theo là tháng 1 với 0,811% và tháng 10 với 0,660%. Ngược lại, tháng 7 ghi nhận mức thấp nhất, chỉ khoảng 0,382%. Các tháng còn lại dao động trong khoảng từ 0,420% đến 0,652%.

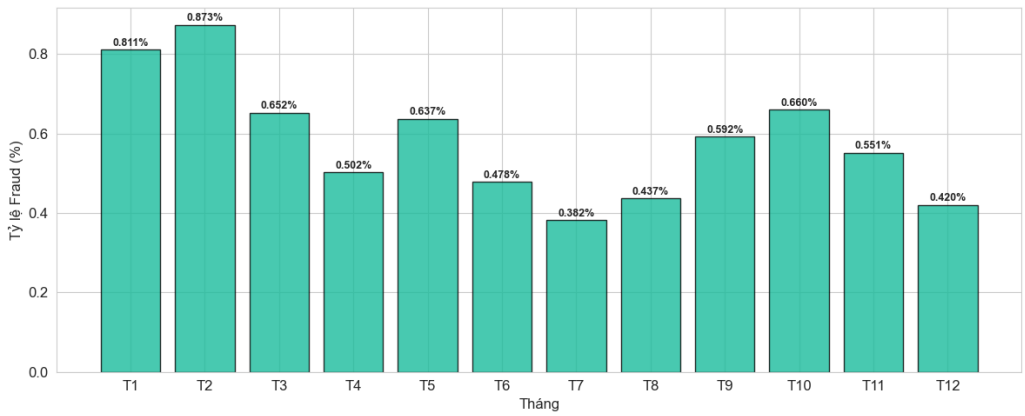

Hình 3.11 Tỷ lệ giao dịch gian lận theo tháng

Nhìn chung, phân tích theo thời gian cho thấy hành vi gian lận không xuất hiện ngẫu nhiên mà có xu hướng tập trung vào một số thời điểm nhất định, đặc biệt là ban đêm, cuối tuần và một vài tháng đầu hoặc cuối năm. Những quan sát này cho thấy các đặc trưng như `hour`, `day_of_week` và `month` có thể đóng vai trò hữu ích trong giai đoạn xây dựng mô hình phát hiện gian lận.

3.5.6 Phân tích gian lận theo bang

Tiếp theo chúng tôi xét đến yếu tố địa lý thông qua thuộc tính `state`, nhằm đánh giá sự khác biệt về mức độ gian lận giữa các bang trong bộ dữ liệu. Để tránh hiện tượng một bang có quá ít giao dịch nhưng lại cho tỷ lệ gian lận cao bất thường, phân tích này chỉ xét các bang có từ 500 giao dịch trở lên.

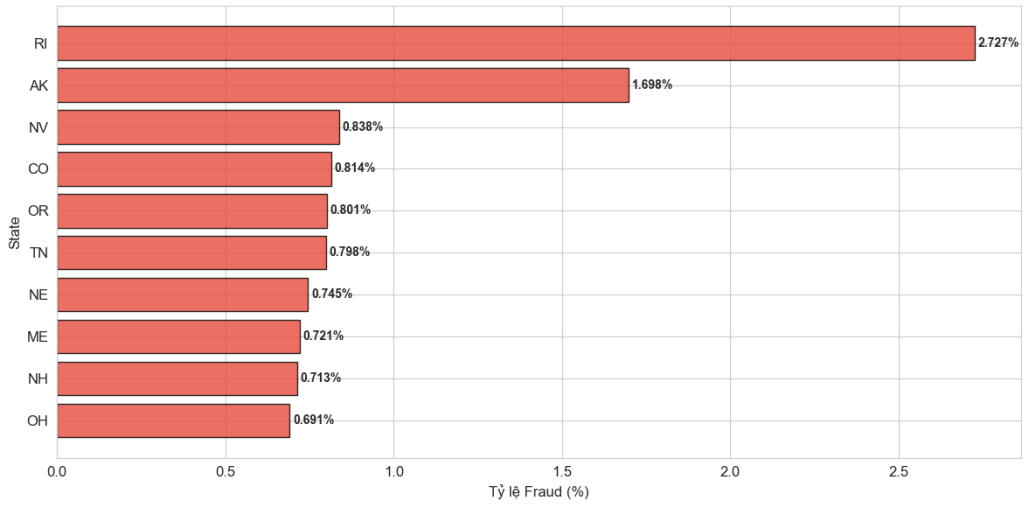

Hình 3.12 Top 10 bang có tỷ lệ giao dịch gian lận cao nhất

Kết quả cho thấy bang RI có tỷ lệ gian lận cao nhất, đạt 2,727%, tương ứng 15

giao dịch gian lận trên tổng số 550 giao dịch. Nói cách khác, cứ 100 giao dịch tại RI thì trung bình có khoảng 2,727 giao dịch bị gắn nhãn gian lận. Xếp sau là bang AK với tỷ lệ 1,698%, tương ứng 36 giao dịch gian lận trên 2.120 giao dịch. Các bang còn lại trong nhóm top 10 gồm NV, CO, OR, TN, NE, ME, NH và OH có tỷ lệ gian lận dao động trong khoảng từ 0,691% đến 0,838%. Nhìn vào kết quả có thể thấy số lượng giao dịch gian lận và tỷ lệ gian lận không hoàn toàn tỷ lệ thuận với nhau. Chẳng hạn, bang OH có 321 giao dịch gian lận, cao hơn nhiều so với RI, nhưng do tổng số giao dịch tại OH lớn hơn đáng kể nên tỷ lệ gian lận chỉ ở mức 0,691%. Trong khi đó, RI chỉ có 15 giao dịch gian lận nhưng vẫn đứng đầu về tỷ lệ do tổng số giao dịch của bang này khá nhỏ.

Phân tích này cho thấy khu vực địa lý có thể mang lại thêm thông tin cho bài toán phát hiện gian lận. Tuy nhiên, cần thận trọng khi diễn giải kết quả, đặc biệt với các bang có quy mô giao dịch không lớn, vì tỷ lệ gian lận có thể biến động mạnh hơn so với các bang có số lượng giao dịch lớn.

3.6 Phân tích khoảng cách giữa khách hàng và merchant

3.7 So sánh tập huấn luyện và tập kiểm tra

CHƯƠNG 4: THỰC NGHIỆM VÀ KẾT QUẢ

4.1 Tiền xử lý dữ liệu

4.2 Xây dựng mô hình

4.3 Đánh giá và so sánh mô hình

4.4 Thực nghiệm Streaming

4.5 Phân tích đồ thị giao dịch

4.6 Thảo luận kết quả

CHƯƠNG 5: KẾT LUẬN

TÀI LIỆU THAM KHẢO

[1] Mỹ Y. (2025, Mar.) Big data là gì? lợi ích – thách thức & Ứng dụng của big data. Truy cập ngày 07/04/2026. [Online]. Available: https://interdata.vn/blog/big-data-la-gi/